



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE CIENCIAS EXACTAS Y NATURALES
DEPARTAMENTO DE COMPUTACIÓN

Correlatos neurales de los modelos computacionales de búsqueda visual híbrida

Tesis de Licenciatura en Ciencias de Datos

Malena Sol Alamo

Director: Juan Esteban Kamienkowski

Codirector: Gonzalo Ruarte

Buenos Aires, 2026

CORRELATOS NEURALES DE MODELOS DE BÚSQUEDA VISUAL HÍBRIDA

La princesa Leia, líder del movimiento rebelde que desea reinstaurar la República en la galaxia en los tiempos ominosos del Imperio, es capturada por las malévolas Fuerzas Imperiales, capitaneadas por el implacable Darth Vader. El intrépido Luke Skywalker, ayudado por Han Solo, capitán de la nave espacial “El Halcón Milenario”, y los androides, R2D2 y C3PO, serán los encargados de luchar contra el enemigo y rescatar a la princesa para volver a instaurar la justicia en el seno de la Galaxia (aprox. 200 palabras).

Palabras claves: Guerra, Rebelión, Wookie, Jedi, Fuerza, Imperio (no menos de 5).

NEURAL CORRELATES OF COMPUTATIONAL MODELS OF HYBRID VISUAL SEARCH

In a galaxy far, far away, a psychopathic emperor and his most trusted servant – a former Jedi Knight known as Darth Vader – are ruling a universe with fear. They have built a horrifying weapon known as the Death Star, a giant battle station capable of annihilating a world in less than a second. When the Death Star’s master plans are captured by the fledgling Rebel Alliance, Vader starts a pursuit of the ship carrying them. A young dissident Senator, Leia Organa, is aboard the ship & puts the plans into a maintenance robot named R2-D2. Although she is captured, the Death Star plans cannot be found, as R2 & his companion, a tall robot named C-3PO, have escaped to the desert world of Tatooine below. Through a series of mishaps, the robots end up in the hands of a farm boy named Luke Skywalker, who lives with his Uncle Owen & Aunt Beru. Owen & Beru are viciously murdered by the Empire’s stormtroopers who are trying to recover the plans, and Luke & the robots meet with former Jedi Knight Obi-Wan Kenobi to try to return the plans to Leia Organa’s home, Alderaan. After contracting a pilot named Han Solo & his Wookiee companion Chewbacca, they escape an Imperial blockade. But when they reach Alderaan’s coordinates, they find it destroyed - by the Death Star. They soon find themselves caught in a tractor beam & pulled into the Death Star. Although they rescue Leia Organa from the Death Star after a series of narrow escapes, Kenobi becomes one with the Force after being killed by his former pupil - Darth Vader. They reach the Alliance’s base on Yavin’s fourth moon, but the Imperials are in hot pursuit with the Death Star, and plan to annihilate the Rebel base. The Rebels must quickly find a way to eliminate the Death Star before it destroys them as it did Alderaan (aprox. 200 palabras).

Keywords: War, Rebellion, Wookie, Jedi, The Force, Empire (no menos de 5).

AGRADECIMIENTOS

holaaaaa. Fusce sapien ipsum, aliquet eget convallis at, adipiscing non odio. Donec porttitor tincidunt cursus. In tellus dui, varius sed scelerisque faucibus, sagittis non magna. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Mauris et luctus justo. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos himenaeos. Mauris sit amet purus massa, sed sodales justo. Mauris id mi sed orci porttitor dictum. Donec vitae mi non leo consectetur tempus vel et sapien. Curabitur enim quam, sollicitudin id iaculis id, congue euismod diam. Sed in eros nec urna lacinia porttitor ut vitae nulla. Ut mattis, erat et laoreet feugiat, lacus urna hendrerit nisi, at tincidunt dui justo at felis. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos himenaeos. Ut iaculis euismod magna et consequat. Mauris eu augue in ipsum elementum dictum. Sed accumsan, velit vel vehicula dignissim, nibh tellus consequat metus, vel fringilla neque dolor in dolor. Aliquam ac justo ut lectus iaculis pharetra vitae sed turpis. Aliquam pulvinar lorem vel ipsum auctor et hendrerit nisl molestie. Donec id felis nec ante placerat vehicula. Sed lacus risus, aliquet vel facilisis eu, placerat vitae augue.

A mi persona favorita.

Índice general

1.. Introducción	1
1.1. Búsqueda visual e híbrida	1
1.2. El modelo nnELM	1
1.3. EEG en búsqueda visual	2
1.4. Pregunta principal y objetivos	3
2.. Materiales y Métodos	5
2.1. Dataset HSEM	5
2.2. El modelo nnELM	6
2.3. Extracción de features del nnELM	8
2.3.1. Notación	8
2.3.2. Procedimiento	9
2.3.3. Features extraídas	10
2.4. Integración de los pipelines	16
2.5. Modelo de TRFs por regresión regularizada	17
2.5.1. Temporal Response Functions (TRFs)	18
2.5.2. Construcción de Matriz de Diseño	18
2.5.3. Estimación Ridge y selección del parámetro de regularización	18
2.6. Metodología de evaluación	19
2.6.1. Construcción Incremental de Modelos	19
2.6.2. Δ AIC con grados de libertad efectivos de Ridge	20
2.6.3. VIF	20
2.6.4. TFCE: Inferencia Estadística Espacio-Temporal	20
2.6.5. Exploración de Transformación de Variables	21
3.. Análisis de Features	23
3.1. Validación computacional de las features	23
3.2. Análisis distribucional	23
3.2.1. Análisis Global	23
3.2.2. Mirada por sujeto	27
3.3. Coherencia con el proceso de búsqueda	29
3.4. Fijaciones consecutivas en misma celda	33
3.5. Diagnóstico de Multicolinealidad	34
4.. Resultados	37
4.1. Resultados con features agregadas	37
4.2. Interpretación de resultados	37
5.. Discusión	39
6.. Conclusiones	41

1. INTRODUCCIÓN

1.1. Búsqueda visual e híbrida

Una estudiante se levanta a la mañana y busca las llaves sobre la mesa desordenada del living. Sale a la calle y, ya en la parada, intenta localizar si alguno de los colectivos que ve a lo lejos es el 37, el que la deja en la facultad. Al llegar a clase, recorre con la mirada el aula buscando las caras conocidas de sus amigos.

La **búsqueda visual** constituye uno de los mecanismos fundamentales mediante el cual los seres humanos interactúan con el entorno: permite extraer información relevante de escenas complejas de forma eficiente. Este proceso se lleva a cabo a través de los movimientos oculares, que se componen de *fijaciones* y *sacadas*. Una *fijación* ocurre cuando el ojo permanece estático sobre una región del espacio, adquiriendo información de calidad. Una *sacada* es el movimiento rápido del ojo entre fijaciones, que redirige la mirada hacia nuevas regiones de interés.

CITA

La secuencia ordenada de fijaciones que realiza un sujeto se denomina *scanpath*. Esta secuencia depende de la tarea que se esté realizando, el contenido de la escena y de las características del objetivo buscado.

Muchas situaciones implican la búsqueda de múltiples objetivos en la escena (por ejemplo, buscar alguna de todas las caras conocidas de un grupo de amigos). Esta tarea se denomina **búsqueda híbrida**: el sujeto mantiene en memoria un conjunto de posibles objetivos y debe comparar simultáneamente lo que percibe en la escena con cada uno de ellos. Este proceso combina los mecanismos cognitivos de la atención y la memoria.

cita

Históricamente, el estudio experimental de la búsqueda visual se llevó a cabo con estímulos artificiales: imágenes de ruido, formas geométricas o ítems sobre fondos uniformes. Este enfoque limita la representatividad de los resultados: las búsquedas reales ocurren en escenas naturales ricas en información contextual.

cita

Para avanzar en esta dirección, se desarrolló el dataset *HSEM* (Hybrid Search Eye Movements), que registra los movimientos oculares de participantes durante una tarea de búsqueda híbrida en escenas naturales. En cada trial, los participantes memorizaron entre uno a cuatro posibles targets, y luego buscaron cualquiera de ellos en una escena compuesta por 16 ítems superpuestos en una fotografía de fondo. Este dataset provee el marco experimental del presente trabajo.

Ruarte y colaboradores (2025)

1.2. El modelo nnELM

La búsqueda visual puede entenderse como un problema de inferencia bajo incertidumbre: en cada fijación el observador incorpora nueva información que lo hace actualizar su creencia de donde está el target. Este proceso puede modelarse dentro del marco bayesiano. Najemnik y Geisler () propusieron el modelo *Ideal Bayesian Searcher* (IBS), en el cual la selección de cada fijación se determina de forma óptima a partir de la evidencia acumulada. Formalmente, el IBS combina una distribución a priori sobre la localización del target, un mapa de visibilidad periférica y una distribución posterior que se actualiza tras cada fijación para maximizar la probabilidad de encontrar el objetivo. Sin embargo, el IBS y sus extensiones inmediatas fueron formulados y evaluados sobre imágenes artificiales que no

año

cita Bujia

Najemnik; Zhou

representaban escenas naturales, lo que limita su aplicabilidad a condiciones de búsqueda realistas.

2022

ar año y cita

Trabajos posteriores extendieron este marco hacia escenas naturales, incorporando redes neuronales profundas para estimar el prior inicial y la similitud visual con el target. El modelo **nnELM** (Neural Network Entropy Limit Minimization) profundizó estas extensiones reemplazando el criterio de optimalidad del IBS y extendiendo el marco a la búsqueda híbrida. El nnELM adopta el criterio de minimización de entropía esperada (ELM) para la selección de fijaciones: en cada paso, el modelo selecciona la región que maximiza la reducción de incertidumbre sobre la ubicación del target. Para operar sobre escenas naturales, incorpora redes neuronales profundas: un mapa de saliencia de la escena inicializa el prior de la escena, y una red neuronal convolucional genera el mapa de similitud entre cada región con el target buscado. Para la búsqueda híbrida, el modelo selecciona el movimiento ocular basándose en el mapa de menor entropía, entre los mapas posteriores de cada target.

a bujia?

1.3. EEG en búsqueda visual

El electroencefalograma (EEG) es una técnica de registro que mide la actividad eléctrica cerebral a través de electrodos ubicados en el cuero cabelludo. La señal registrada representa la suma de potenciales de grandes poblaciones neuronales que se activan de forma sincrónica. Particularmente, es una herramienta que permite estudiar los procesos cognitivos que operan durante la búsqueda visual.

El método clásico para estudiar la actividad neural durante la búsqueda visual consiste en obtener **fixation-related potentials** (FRPs). El procedimiento alinea la señal continua de EEG con el inicio de cada fijación ocular y promedia la señal resultante a lo largo de todos los eventos del mismo tipo para un mismo sujeto. El promediado cancela las fluctuaciones aleatorias no relacionadas con el evento de interés, dejando visible la respuesta neural sistemáticamente asociada a cada fijación.

Sin embargo, este enfoque presenta una limitación fundamental. Durante la búsqueda visual, las fijaciones oculares tienen una duración típica de 200–300 ms, mientras que las respuestas neurales evocadas por cada fijación se extienden entre 400 y 600 ms. Como consecuencia, la respuesta a una fijación aún terminó cuando la siguiente ya comenzó, de modo que las señales neurales de fijaciones consecutivas se **superponen** en el registro continuo de EEG. El promediado clásico no puede separar estas contribuciones, por lo que los FRPs obtenidos no reflejan la respuesta independiente a cada fijación sino una mezcla contaminada por los eventos adyacentes.

PAPER DA-
N

Para abordar este problema, se propusieron métodos de **deconvolución lineal** que modelan la señal continua de EEG cómo la suma de respuestas evocadas por múltiples eventos simultáneos. La idea central es plantear el problema como una **regresión lineal**: se construye una **matriz de diseño** en la que cada fila corresponde a un punto temporal del registro continuo de EEG, y las columnas corresponden a los predictores desplazados temporalmente. Para cada evento de interés (por ejemplo, si el target está o no presente en la fijación), se incluyen copias de la señal desplazadas a distintos tiempos (lags) dentro de una ventana de análisis definida. De este modo, los coeficientes estimados por la regresión en cada retardo constituyen la respuesta neural asociada a ese evento a lo largo del tiempo, lo que se denomina **Temporal Response Function (TRF)**. Este enfoque **deconvoluciona las respuestas solapadas**, permitiendo recuperar la contribución independiente de cada

evento sobre la señal EEG.

1.4. Pregunta principal y objetivos

El modelo *nnELM* genera, en cada ciclo fijación por fijación, un conjunto de mapas que representan distintos aspectos del proceso de búsqueda: el prior espacial provisto por DeepGaze II, el mapa de similitud con el target generado por ResNet, el mapa de visibilidad periférica, y el posterior bayesiano resultante de integrar esa evidencia de forma acumulativa a lo largo del scanpath. Por otro lado, el framework de TRFs por regresión regularizada permite estimar, a partir de la señal EEG continua registrada con los movimientos oculares, la contribución de predictores definidos a nivel de fijación a la respuesta neural. Esto abre una pregunta que articula ambas líneas de investigación:

Pregunta Principal: Dado que contamos con los mapas generados por el modelo *nnELM* y con el framework de análisis de TRFs, ¿es posible diseñar y extraer features a nivel de fijación a partir de dichos mapas que tengan correlatos en la señal EEG registrada durante una tarea de búsqueda visual híbrida?

Esta pregunta es relevante tanto desde el punto de vista teórico: permitiría identificar qué aspectos del proceso de búsqueda computacionalmente definido se manifiestan en la actividad neural, como desde el metodológico: implica compatibilizar dos pipelines con distintos criterios de preprocesamiento y distintas resoluciones espaciales (el modelo opera sobre una grilla de celdas; el algoritmo de fijaciones EEG opera píxel a píxel).

Para abordarla, se plantean tres objetivos específicos:

1. **Diseño, extracción y validación de features del modelo *nnELM* sobre el dataset HSEM.** Diseñar features a nivel de fijación a partir de los mapas generados por el modelo, aplicarlo sobre los scanpaths del dataset HSEM y extraer dichas features para cada fijación. Validar su distribución, coherencia con las condiciones experimentales y su comportamiento a lo largo de la progresión del trial.
2. **Compatibilización de los pipelines de movimientos oculares y EEG.** Dado que el modelo *nnELM* opera sobre la representación en celdas de la escena, y que el pipeline de EEG utiliza los timestamps de fijaciones detectados por un algoritmo distinto, es necesario resolver el problema de alineación entre ambos conjuntos de fijaciones. Esto incluye definir una estrategia de asignación de las features del modelo a las fijaciones del análisis EEG, y analizar los casos en que múltiples fijaciones consecutivas corresponden a la misma celda del modelo.
3. **Evaluación de la contribución de las features a la predicción de la señal EEG.** Incorporar las features del *nnELM* como predictores adicionales en el modelo de regresión regularizada, siguiendo el esquema de crecimiento gradual de complejidad de [. Evaluar su contribución mediante \$\Delta AIC\$ con grados de libertad efectivos de Ridge](#), diagnosticar la multicolinealidad con VIF, y determinar la significancia estadística de los efectos mediante TFCE.

cita

2. MATERIALES Y MÉTODOS

2.1. Dataset HSEM

Dataset

El dataset utilizado en este trabajo fue recolectado por () mediante el registro simultáneo de EEG y movimientos oculares durante una tarea de búsqueda híbrida en escenas naturales.

Participantes

En el experimento participaron 42 sujetos: 16 de la Universidad de Buenos Aires (UBA; edad: 19–40 años, mediana = 25) y 26 de la University of Nottingham (UoN; edad: 18–36 años, mediana = 20). Todos los participantes reportaron visión normal o corregida a normal y desconocían los objetivos del experimento. El protocolo fue aprobado por los comités de ética de ambas instituciones, y todos los participantes firmaron un consentimiento informado.

Estímulos y tarea

Se utilizaron 210 escenas naturales construidas superponiendo 16 ítems (objetos, animales o personas) sobre fondos fotográficos. Los ítems fueron extraídos de los datasets COCO e ImageNet , redimensionados a un máximo de 80x80 píxeles, y dispuestos de forma semánticamente coherente con la escena. Las imágenes resultantes tenían una resolución de 1280×1024 píxeles.

Cada trial consistió en dos fases (Figura ??). En la *fase de memorización*, los participantes tuvieron que retener entre 1, 2 o 4 ítems (Memory Set Size, $MSS \in \{1, 2, 4\}$) durante 2, 3.5 o 5 segundos respectivamente. En la *fase de búsqueda visual*, dispusieron de hasta 10 segundos para indicar si alguno de los ítems memorizados estaba presente en la escena. El target estuvo presente en el 50 % de los trials. El experimento se organizó en 7 bloques de 30 trials, con una duración total aproximada de 50 minutos.




Fig. 2.1: Ejemplo de scanpath obtenido del experimento.

PENDIENTE: E
ria bueno aca ag
un analisis del da
set. Cual es el mi
de fijaciones, ma
cuantos usuarios
contraron el targ
Cuantas imagene
por usuario, cual
target encontrad
imagen, etc

nombre

cita

cita

2.2. El modelo nnELM

cuarto 2025

El modelo nnELM implementa un esquema de inferencia bayesiana iterativa: en cada fijación, integra nueva evidencia visual para actualizar una distribución de probabilidad posterior sobre la localización del target, y selecciona la siguiente fijación según un criterio de minimización de entropía esperada.




Fig. 2.2: Flujo nnELM

Representación Espacial

El modelo no opera directamente sobre los píxeles de la imagen sino sobre una representación espacial discreta. Las imágenes son redimensionadas a 768×1024 píxeles previo al procesamiento y divididas en una grilla de 24×32 celdas de 32×32 píxeles cada una. Todos los cálculos del modelo se realizan a esta resolución de grilla, por lo que cada mapa interno tiene dimensiones 24×32 . Las coordenadas de fijación, registradas originalmente en píxeles, se mapean a la celda correspondiente antes de ser procesadas por el modelo.

Prior inicial

Antes de la primera fijación, el modelo inicializa la distribución a priori sobre la localización del target mediante DeepGaze II, una red neuronal convolucional entrenada para predecir dónde mira el sujeto al observar una imagen sin un objetivo de búsqueda predeterminado. Este mapa de saliencia modela la atención de forma guiada por el estímulo (lo que se conoce como bottom-up): captura las características visuales de bajo y alto nivel que atraen la mirada basándose en propiedades intrínsecas de la escena. De esta manera, la prior funciona como una estimación inicial de las regiones más llamativas en un primer vistazo, sirviendo como punto de partida antes de que los mecanismos del modelo empiecen a guiar los movimientos en función del objetivo de la búsqueda.

Mapa de similitud con el target

El mapa de similitud (ϕ) cuantifica el parecido entre cada región de la imagen y el target buscado. Se construye dividiendo la imagen en bloques de 224×224 píxeles que

son procesados por una red ResNeXt-101 32×8d preentrenada. El target es reescalado a 128×128 píxeles y procesado por la misma red. Luego, el mapa de características (*feature map*) de la última capa convolucional de cada bloque de imagen es convolucionado con el mapa de características del target.

cita

Mapa de visibilidad

El ojo humano no percibe la escena con igual resolución en todas las direcciones: la capacidad de detección es máxima en la fovea y decae progresivamente hacia la periferia. El mapa de visibilidad (d) modela esta propiedad asignando a cada región de la imagen un valor que refleja cuánta información visual puede adquirirse desde el punto de fijación actual $k(t)$.

Formalmente, $d_{ik(t)}$ se define como una gaussiana 2D $\mathcal{N}(\mu, \Sigma)$ centrada en $k(t)$, donde la matriz de covarianza:

$$\Sigma = \begin{pmatrix} 2600 & 0 \\ 0 & 4000 \end{pmatrix} \text{ px}^2 \quad (2.1)$$

fue estimada en a partir de mediciones empíricas de la excentricidad visual de participantes humanos en experimentos de búsqueda visual . Los valores más altos de d cerca del centro de fijación y su decaimiento hacia la periferia capturan el gradiente de resolución del sistema visual.

cita Bujia 2022

cita Najemnik 20

Evidencia visual

La evidencia visual $W_{ik(t)}$ integra la similitud del target con la visibilidad periférica y foveal. Sus valores se muestrean de una distribución normal 2D:

$$\widetilde{W}_{ik(t)} \sim \mathcal{N}(\widetilde{\mu}_{ik(t)}, \widetilde{\sigma}_{ik(t)}^2) \quad (2.2)$$

donde la media y la varianza están definidas como:

$$\widetilde{\mu}_{ik(t)} = \mu_{ik(t)} \cdot \left(d_{ik(t)} + \frac{1}{2}\right) + \phi_i \cdot \left(\frac{3}{2} - d_{ik(t)}\right) \quad (2.3)$$

$$\widetilde{\sigma}_{ik(t)} = \frac{1}{a \cdot d_{ik(t)} + b} \quad (2.4)$$

con $\mu_{ik(t)} \in \{-0,5, 0,5\}$ según si el target está o no presente en la ubicación i , $\phi_i \in [-0,5, 0,5]$ el valor del mapa de similitud, y a, b parámetros aprendidos. La evidencia visual integra dos fuentes de información que reflejan las propiedades del sistema visual humano: la región foveal, donde la resolución es alta y permite identificar con precisión si el target está presente, y la región periférica, donde la resolución es menor pero permite detectar características generales de la escena que guían hacia dónde mover la mirada. La operación máx entre ambos términos asegura que en cada fijación se aproveche la fuente más informativa disponible.

Actualización del posterior

Tras cada fijación t en la posición $k(t)$, el modelo actualiza la distribución posterior sobre todas las posibles localizaciones del target:

$$p_i(T) = \frac{\text{prior}(i) \prod_{t=1}^T \exp\left(d_{ik(t)}^2 W_{ik(t)}\right)}{\sum_{j=1}^n \text{prior}(j) \prod_{t=1}^T \exp\left(d_{jk(t)}^2 W_{jk(t)}\right)} \quad (2.5)$$

donde i y j determinan la ubicación en la imagen y n es el número total de ubicaciones posibles. El posterior resultante se convierte en el prior del siguiente paso.

Criterio de selección: minimización de entropía esperada

La siguiente fijación se selecciona según el criterio ELM (*Entropy Limit Minimization*) que elige la posición $k(T+1)$ que maximiza la reducción esperada de entropía en el posterior:

$$\mathbb{E}[\Delta H(T+1) \mid k(T+1)] = \frac{1}{2} \sum_{i=1}^n p_i(T) d_{ik(T+1)}^2 \quad (2.6)$$

En cada paso, el modelo selecciona la región que minimiza esta cantidad, dirigiendo la mirada hacia las ubicaciones que más reducen la incertidumbre sobre la localización del target.

Extensión a búsqueda híbrida

En la búsqueda híbrida, el observador debe buscar simultáneamente cualquiera de los M targets almacenados en memoria ($MSS \in \{1, 2, 4\}$). Para abordar esto, el modelo computa un posterior independiente $p_i^{(m)}(T)$ para cada target m del memory set. La selección de la siguiente fijación se realiza aplicando el criterio ELM sobre el posterior de menor entropía entre todos los targets:

$$m^* = \arg \min_m H\left(p^{(m)}(T)\right) \quad (2.7)$$

donde $H(\cdot)$ denota la entropía de Shannon. Esta estrategia, denominada *MinEntropy*, prioriza el target sobre el cual el modelo tiene mayor certeza acumulada, y fue la que demostró mejor desempeño en comparación con estrategias alternativas.

2.3. Extracción de features del nnELM

La motivación detrás de este procedimiento es extraer, a partir del modelo nnELM, variables internas que capturen distintas dimensiones del proceso de búsqueda visual en cada fijación. Estas variables se incorporan posteriormente como predictores en el modelo de regresión EEG de Care et al., con el fin de evaluar si las representaciones computacionales del modelo tienen correlatos en la actividad cerebral registrada durante la tarea de búsqueda híbrida.

2.3.1. Notación

Se emplea la siguiente notación para describir las features extraídas del modelo nnELM.

Índices

- t — índice de fijación dentro de un trial
- i, j — índice de celda en la grilla
- s — índice de sujeto
- n — índice de imagen

Coordenadas de fijación

La posición de fijación $k(t)$ empleada en la notación del modelo se representa explícitamente como un par de coordenadas en la grilla:

$$k(t) = (g_y, g_x), \quad g_y \in \{0, \dots, 23\}, \quad g_x \in \{0, \dots, 31\} \quad (2.8)$$

Adicionalmente, se distinguen las siguientes representaciones de la posición de fijación:

- (g_y, g_x) — coordenadas en la grilla del modelo
- (x_k, y_k) — coordenadas en píxeles de pantalla
- (x_m, y_m) — coordenadas mapeadas a la resolución del mapa de saliencia

Mapas

- S — mapa de saliencia
- ϕ — mapa de similitud con el target
- d — mapa de visibilidad
- $W_{ik(t)}$ — evidencia visual
- $p_i(T)$ — distribución posterior tras T fijaciones
- E — mapa de entropías esperadas

Bloque de píxeles

Se define $B_{k(t)}$ como el conjunto de píxeles correspondientes a la celda $k(t) = (g_y, g_x)$ en un mapa dado, donde $c = 32$ px es el tamaño de celda:

$$B_{k(t)} = \{(y, x) : c \cdot g_y \leq y < c \cdot (g_y + 1), \quad c \cdot g_x \leq x < c \cdot (g_x + 1)\} \quad (2.9)$$

2.3.2. Procedimiento

El modelo nnELM fue ejecutado sobre los scanpaths del dataset para cada combinación de sujeto, imagen y target. Durante la ejecución, se seleccionaron y almacenaron los mapas internos generados en cada fijación t que resultaban relevantes para caracterizar el estado del proceso de búsqueda.

Los mapas se clasifican en **estáticos**, cuando se computan una única vez por combinación sujeto–imagen–target y permanecen constantes a lo largo del scanpath, y **dinámicos**, cuando se actualizan en cada fijación t a medida que el modelo acumula evidencia visual.

- **Mapa de saliencia** (estático): distribución de atención visual bottom-up sobre la escena generada por DeepGaze II. Opera como prior inicial $p_i(0)$ del modelo.
- **Mapa de similitud con el target ϕ** (estático): cuantifica el parecido entre cada región de la imagen y el target buscado, generado por la red ResNeXt.
- **Mapa de visibilidad d** (estático): gaussiana 2D que modela el decaimiento de la resolución visual con la excentricidad respecto al punto de fijación. Al ser un kernel fijo, se precalculó independientemente de la dinámica de búsqueda.
- **Evidencia visual $W_{ik(t)}$** (dinámico): valor muestreado de la distribución normal cuya media y varianza dependen de ϕ y d en la posición de fijación actual.
- **Posterior $p_i(T)$** (dinámico): distribución de probabilidad sobre todas las posibles localizaciones del target, actualizada tras cada fijación.
- **Mapa de entropías esperadas** (dinámico): para cada posible próxima fijación $k(T+1)$, almacena el valor de $\mathbb{E}[\Delta H(T+1) | k(T+1)]$. Es a partir de este mapa que el modelo selecciona la siguiente fijación óptima.
- **Coordenadas de fijación (x_k, y_k)** (dinámico): posición de la fijación actual en píxeles.

A partir de estos mapas se calcularon las siguientes features, organizadas en cuatro categorías según su interpretación.




Fig. 2.3: Ejemplo de los mapas internos generados por el modelo nnELM en cada fijación.

2.3.3. Features extraídas

Información bottom-up

Estas features capturan las características visuales de bajo nivel de la escena en el punto de fijación, independientemente del target buscado. Se derivan del mapa de saliencia generado por DeepGaze II.

Sea S el mapa de saliencia de la escena y $k(t) = (g_y, g_x)$ la celda correspondiente a la fijación t . El bloque de píxeles asociado a la celda es:

$$B_{k(t)} = \{(y, x) : c \cdot g_y \leq y < c \cdot (g_y + 1), c \cdot g_x \leq x < c \cdot (g_x + 1)\} \quad (2.10)$$

con $c = 32$ px. A partir de $B_{k(t)}$ se calculan:

Feature 1: `saliencia_media`

Descripción: Media de S sobre los píxeles de la celda $k(t)$.

Ecuación:

$$\text{saliencia_media} := \frac{1}{|B_{k(t)}|} \sum_{(y,x) \in B_{k(t)}} S[y, x] \quad (2.11)$$

Feature 2: `saliencia_mediana`

Descripción: Mediana de S sobre los píxeles de la celda $k(t)$.

Ecuación:

$$\text{saliencia_mediana} := \text{mediana}\{S[y, x] : (y, x) \in B_{k(t)}\} \quad (2.12)$$

Feature 3: `saliencia_pixel`

Descripción: Valor de S en el píxel (x_m, y_m) obtenido mapeando las coordenadas de pantalla (x_k, y_k) a la resolución del mapa.

Ecuación:

$$\text{saliencia_pixel} := S[y_m, x_m] \quad (2.13)$$

Similitud con el target

Sea ϕ el mapa de similitud con el target. Las features se calculan de forma análoga a las de información bottom-up, reemplazando S por ϕ :

Feature 4: `similitud_media`

Descripción: Media de ϕ sobre los píxeles de la celda $k(t)$.

Ecuación:

$$\text{similitud_media} := \frac{1}{|B_{k(t)}|} \sum_{(y,x) \in B_{k(t)}} \phi[y, x] \quad (2.14)$$

Feature 5: `similitud_mediana`

Descripción: Mediana de ϕ sobre los píxeles de la celda $k(t)$.

Ecuación:

$$\text{similitud_mediana} := \text{mediana}\{\phi[y, x] : (y, x) \in B_{k(t)}\} \quad (2.15)$$

Feature 6: `similitud_pixel`

Descripción: Valor de ϕ en el píxel exacto de fijación.

Ecuación:

$$\text{similitud_pixel} := \phi[y_m, x_m] \quad (2.16)$$

Estado interno del proceso bayesiano

Estas features reflejan el estado de la inferencia bayesiana en la fijación t : cuánta evidencia se acumuló, cómo se distribuye la certeza sobre la localización del target, y la tensión entre información foveal y periférica.

Feature 7: `evidencia_visual`

Descripción: Sea W el mapa de evidencia visual de dimensiones $T \times 24 \times 32$, donde $W[t]$ contiene la evidencia visual en el paso t . La feature se obtiene evaluando W en las coordenadas de grilla de la fijación actual.

Ecuación:

$$\text{evidencia_visual} := W[t, g_y, g_x] \quad (2.17)$$

A partir del mapa de visibilidad $d_{ik(t)}$ se definen dos kernels de visibilidad:

$d_{ik(t)}^2$: mapa base elevado al cuadrado, de caída rápida, que restringe la información a la región foveal

(2.18)

$$d'_{ik(t)} = d_{ik(t)}^p \cdot \frac{\max_i(d_{ik(t)}^2)}{\max_i(d_{ik(t)}^p)}, \quad p = 0,2 \quad (2.19)$$

Elevar $d_{ik(t)}$ a un exponente $p < 1$ aplanar la curva y ensancha sus colas, permitiendo que el modelo incorpore información de objetos lejanos a la fijación. El factor de reescalado $\max_i(d_{ik(t)}^2) / \max_i(d_{ik(t)}^p)$ fuerza a $d'_{ik(t)}$ a compartir el rango de valores de $d_{ik(t)}^2$, preservando la comparabilidad entre ambos kernels. El mapa de competencia foveal-periférica se define entonces como:

$$C_{ik(t)} = \max(W_{ik(t)} \cdot d_{ik(t)}^2, W_{ik(t)} \cdot d'_{ik(t)}) \quad (2.20)$$

donde el $\max$ opera elemento a elemento sobre las celdas i . A partir de C_t se calculan:

Feature 8: `competencia_fp_var`

Descripción: Varianza espacial de la matriz de competencia foveal-periférica C_t .

Ecuación:

$$\text{competencia_fp_var} := \text{Var}(C_t) \quad (2.21)$$

Feature 9: `competencia_fp_media`

Descripción: Media espacial de la matriz de competencia foveal-periférica C_t .

Ecuación:

$$\text{competencia_fp_media} := \frac{1}{24 \cdot 32} \sum_{i,j} C_t[i, j] \quad (2.22)$$

Feature 10: `competencia_fp_max`

Descripción: Valor máximo de la matriz de competencia foveal-periférica C_t .

Ecuación:

$$\text{competencia_fp_max} := \max_{i,j} C_t[i, j] \quad (2.23)$$

Feature 11: posterior

Descripción: Sea $p[t]$ la distribución posterior en la fijación t , de dimensiones 24×32 . La feature se obtiene evaluando $p[t]$ en las coordenadas de grilla de la fijación actual.

Ecuación:

$$\text{posterior} := p[t, g_y, g_x] \quad (2.24)$$

Las dos features de entropía del prior son estáticas: se computan una única vez por combinación sujeto–imagen–target y se asignan a todas las fijaciones del trial.

Sea $\tilde{S}$ el mapa de saliencia normalizado a resolución de grilla (24×32), definido como:

$$\tilde{S} = \frac{S}{\sum_{i,j} S[i, j]} \quad (2.25)$$

Las features se calculan como la entropía de Shannon de la distribución:

Feature 12: entropia_prior_saliencia

Descripción: Entropía de Shannon del mapa de saliencia normalizado $\tilde{S}$. Feature estática.

Ecuación:

$$\text{entropia_prior_saliencia} := - \sum_{i,j} \tilde{S}[i, j] \log \tilde{S}[i, j] \quad (2.26)$$

Se añade un término de estabilidad numérica $\varepsilon = 10^{-12}$ dentro del logaritmo para evitar indeterminaciones cuando algún valor es cero.

Feature 13: entropia_posterior

Descripción: Entropía de Shannon del posterior en la fijación t , calculada celda a celda sobre toda la grilla.

Ecuación:

$$\text{entropia_posterior} := H(p[t]) = - \sum_{i,j} p[t][i, j] \log p[t][i, j] \quad (2.27)$$

donde se añade $\varepsilon = 10^{-12}$ dentro del logaritmo por estabilidad numérica.

Feature 14: ganancia_informacion

Descripción: Divergencia KL entre el posterior en la fijación t y el posterior en la fijación anterior $t - 1$.

Ecuación:

$$\text{ganancia_informacion} := D_{KL}(p[t] \| p[t - 1]) = \sum_{i,j} p[t][i, j] \log \frac{p[t][i, j]}{p[t - 1][i, j]} \quad (2.28)$$

donde se añade $\varepsilon = 10^{-12}$ en numerador y denominador por estabilidad numérica.

Calidad de la decisión

Estas features comparan la fijación realizada por el sujeto con la decisión óptima según el modelo nnELM, cuantificando en qué medida el comportamiento humano se aparta de la estrategia de minimización de entropía.

Sea $E[t]$ el mapa de ganancia de información esperada en la fijación t , donde $E[t][i, j]$ representa la ganancia de información esperada si la siguiente fijación fuera la celda (i, j) :

$$E[t][i, j] = H(p[t]) - \mathbb{E}[H(p[t+1]) \mid k(t+1) = (i, j)] \quad (2.29)$$

Maximizar $E[t]$ es equivalente a minimizar la entropía esperada del posterior, que es el criterio ELM descrito en la sección 2.2.

Feature 15: `gap_entropia`

Descripción: Diferencia entre la ganancia de información esperada en la fijación óptima del modelo y la obtenida en la fijación efectiva del sujeto en $t + 1$. Cuantifica la suboptimalidad de la decisión humana respecto al criterio ELM.

Ecuación:

$$\text{gap_entropia} := \max_{i,j} E[t][i, j] - E[t][g_y^{t+1}, g_x^{t+1}] \quad (2.30)$$

La feature `gap_entropia` no está definida para la última fijación de cada trial, dado que no existe fijación $t + 1$.

Sea (g_y^*, g_x^*) la celda óptima según el modelo en la fijación t , definida como:

$$(g_y^*, g_x^*) = \arg \max_{i,j} E[t][i, j] \quad (2.31)$$

Las features de distancia comparan esta celda con la fijación efectivamente realizada por el sujeto en $t + 1$:

Feature 16: `distancia_grilla`

Descripción: Distancia euclídea en celdas entre la fijación óptima del modelo y la fijación efectiva del sujeto en $t + 1$.

Ecuación:

$$\text{distancia_grilla} := \sqrt{(g_y^{t+1} - g_y^*)^2 + (g_x^{t+1} - g_x^*)^2} \quad (2.32)$$

Feature 17: `distancia_pixels`

Descripción: Distancia equivalente en píxeles, obtenida multiplicando por el tamaño de celda $c = 32$ px.

Ecuación:

$$\text{distancia_pixels} := c \cdot \text{distancia_grilla} \quad (2.33)$$

Las features `distancia_grilla` y `distancia_pixels` no están definidas para la última fijación de cada trial.

Competencia entre candidatos

Sean $E^{(1)}[t]$ y $E^{(2)}[t]$ el mayor y segundo mayor valor del mapa $E[t]$, respectivamente:

$$E^{(1)}[t] = \max_{i,j} E[t][i, j], \quad E^{(2)}[t] = \max_{i,j \neq \arg \max} E[t][i, j] \quad (2.34)$$

Feature 18: `competencia_ratio`

Descripción: Cociente entre el segundo y el primer mayor valor del mapa EIG. No está definida cuando $E^{(1)}[t] = 0$.

Ecuación:

$$\text{competencia_ratio} := \frac{E^{(2)}[t]}{E^{(1)}[t]} \quad (2.35)$$

Sea $N = 24 \times 32 = 768$ el número total de celdas de la grilla. Se define el conjunto de celdas candidatas en la fijación t como aquellas cuyo valor en el mapa EIG supera el 95 % del valor máximo:

$$\mathcal{K}_t = \{(i, j) : E[t][i, j] \geq 0,95 \cdot E^{(1)}[t]\} \quad (2.36)$$

Feature 19: `competencia_densidad`

Descripción: Cardinalidad del conjunto de celdas candidatas.

Ecuación:

$$\text{competencia_densidad} := |\mathcal{K}_t| \quad (2.37)$$

Feature 20: `competencia_densidad_norm`

Descripción: Proporción de celdas candidatas sobre el total de la grilla.

Ecuación:

$$\text{competencia_densidad_norm} := \frac{|\mathcal{K}_t|}{N} \quad (2.38)$$

Tab. 2.1: Resumen de las features extraídas, organizadas por categoría.

#	Nombre	Categoría	Tipo
1	<code>saliencia_media</code>	Bottom-up	Estática
2	<code>saliencia_mediana</code>	Bottom-up	Estática
3	<code>saliencia_pixel</code>	Bottom-up	Estática
4	<code>similitud_media</code>	Similitud con target	Estática
5	<code>similitud_mediana</code>	Similitud con target	Estática
6	<code>similitud_pixel</code>	Similitud con target	Estática
7	<code>evidencia_visual</code>	Estado interno del proceso bayesiano	Dinámica
8	<code>competencia_fp_var</code>	Estado interno del proceso bayesiano	Dinámica
9	<code>competencia_fp_media</code>	Estado interno del proceso bayesiano	Dinámica
10	<code>competencia_fp_max</code>	Estado interno del proceso bayesiano	Dinámica
11	<code>posterior</code>	Estado interno del proceso bayesiano	Dinámica
12	<code>entropia_prior_saliencia</code>	Estado interno del proceso bayesiano	Estática
13	<code>entropia_posterior</code>	Estado interno del proceso bayesiano	Dinámica
14	<code>ganancia_informacion</code>	Estado interno del proceso bayesiano	Dinámica
15	<code>gap_entropia</code>	Calidad de decisión	Dinámica
16	<code>distancia_grilla</code>	Calidad de decisión	Dinámica
17	<code>distancia_pixels</code>	Calidad de decisión	Dinámica
18	<code>competencia_ratio</code>	Competencia candidatos	Dinámica
19	<code>competencia_densidad</code>	Competencia candidatos	Dinámica
20	<code>competencia_densidad_norm</code>	Competencia candidatos	Dinámica

2.4. Integración de los pipelines

La incorporación de las features extraídas del nnELM al modelo de TRFs por regresión regularizada requiere compatibilizar dos pipelines que difieren en dos aspectos: el algoritmo de detección de fijaciones y la resolución espacial.

Algoritmos de detección de fijaciones

rar algoritmo

El pipeline de EEG utiliza el algoritmo para detectar fijaciones y sacadas a partir de la señal del eye-tracking. El modelo nnELM, en cambio, fue diseñado para generar sus propios scanpaths internos a partir de su mecanismo de decisión. Dado que el análisis del EEG requiere que los eventos estén alineados con la señal cerebral, se forzó al modelo nnELM a utilizar cómo input las coordenadas de fijación del pipeline del EEG, en lugar de generar su propio scanpath. De esta manera, cómo resultado cada fijación del scanpath de obtuvo los valores de las features calculadas por el nnELM.

Resolución espacial: celdas vs. píxeles

El modelo nnELM opera sobre una representación espacial discreta de la imagen, dividida en una grilla de 24×32 celdas de 32×32 píxeles cada una. Como consecuencia, las features extraídas del modelo toman un valor por celda, no por píxel. El pipeline del EEG, en cambio, registra la posición de cada fijación a nivel pixel. Para asignar el valor de cada feature a cada fijación, se mapeó la coordenada de fijación a la celda correspondiente de la grilla.

Una consecuencia de esta discretización es que dos fijaciones consecutivas que caen dentro de la misma celda podrían recibir el mismo valor en las features extraídas del modelo nnELM. Sin embargo, esto sucede en las features estáticas del modelo (que no dependen del estado interno del modelo en cada paso). En las features dinámicas no sucede: entre fijación y fijación el modelo actualiza su estado interno, haciendo que el valor de las features cambien aunque caigan dentro de la misma celda.

Feature	% idénticas	Tipo
saliencia_media	100.0 %	estática
saliencia_mediana	100.0 %	estática
saliencia_pixel	54.9 %	estática
similitud_media	100.0 %	estática
similitud_mediana	100.0 %	estática
similitud_pixel	37.9 %	estática
entropia_prior_saliencia	100.0 %	estática
competencia_densidad	66.8 %	dinámica
competencia_densidad_norm	66.8 %	dinámica
distancia_grilla	58.1 %	dinámica
distancia_pixels	58.1 %	dinámica
gap_entropia	3.1 %	dinámica
evidencia_visual	0.0 %	dinámica
competencia_fp_var	0.0 %	dinámica
competencia_fp_media	0.0 %	dinámica
competencia_fp_max	0.0 %	dinámica
posterior	0.0 %	dinámica
entropia_posterior	0.0 %	dinámica
ganancia_informacion	0.0 %	dinámica
competencia_ratio	0.0 %	dinámica

Tab. 2.2: Proporción de pares de fijaciones consecutivas en la misma celda ($N = 2,908$) con valores idénticos para cada feature. Las features estáticas no dependen de la secuencia de fijaciones, por lo que presentan redundancia total o parcial. Las features dinámicas se actualizan en cada paso del modelo, resultando en valores distintos incluso cuando dos fijaciones caen en la misma celda.

2.5. Modelo de TRFs por regresión regularizada

El objetivo principal de esta tesis es investigar si las features extraídas del modelo nnELM tienen correlatos con la actividad neural. El análisis de la actividad cerebral durante las tareas de búsqueda visual tiene una dificultad particular: las respuestas cerebrales de fijaciones sucesivas se solapan temporalmente. La duración típica de una fijación presenta

o variables, renombrar

una media de 219ms, un tiempo considerablemente menor a la ventanal temporal necesaria para capturar una respuesta completa, la cual se extiende a lo largo de 600ms.

2.5.1. Temporal Response Functions (TRFs)

Una Temporal Response Function (TRF) es la respuesta neural estimada asociada a un predictor específico en función del tiempo relativo al onset del evento. Para cada variable del modelo, la TRF es una curva que indica cuánto varía la señal EEG en cada retardo temporal ante un cambio unitario de ese predictor: si la TRF de un predictor muestra un pico positivo a los 300ms, significa que en promedio la señal EEG aumenta 300ms después de que ese evento ocurre. De esta manera, el conjunto de TRFs del modelo describe cómo cada variable de interés modula la actividad cerebral a lo largo del tiempo.

2.5.2. Construcción de Matriz de Diseño

El framework de TRFs por Regresión Regularizadas representa la señal EEG de cada electrodo como una combinación lineal de las respuestas a distintos tipos de eventos. Por ejemplo, para un solo predictor x con ventana de L lags:

$$r(t) = \sum_{\tau=0}^L w(\tau) \cdot x(t - \tau) + \varepsilon(t) \quad (2.39)$$

donde $r(t)$ es la señal EEG en el instante t ; $x(t - \tau)$ es el valor del predictor τ muestras antes; $w(\tau)$ son los coeficientes que se quieren estimar (la TRF) y $\varepsilon(t)$ es el error residual. La TRF es la secuencia de coeficientes $w(\tau)$ para cada lag τ .

Para cada participante se construye una matriz de diseño M que codifica, para cada muestra temporal de la señal EEG continua, qué eventos ocurrieron en una ventana temporal definida.

Cada columna de M corresponde a un predictor desplazado en el tiempo (llamado lag). En otras palabras, para cada variable de interés y cada retardo temporal dentro de la ventana, se incluye una columna que indica el valor de esa variable en ese retardo.

	variable_1 (binaria)			variable_2 (binaria)			variable_3 (continua)		
	τ_0	τ_1	τ_2	τ_0	τ_1	τ_2	τ_0	τ_1	τ_2
t_1	1	0	0	0	0	0	0.8	0.0	0.0
t_2	0	1	0	0	0	0	0.0	0.8	0.0
t_3	0	0	1	1	0	0	0.0	0.0	0.8
t_4	0	0	0	0	1	0	0.0	0.0	0.0
t_5	1	0	0	0	0	1	0.3	0.0	0.0

Tab. 2.3: Ejemplo simplificado de la matriz de diseño M para tres predictores y una ventana de 3 lags. Cada fila corresponde a una muestra temporal de la señal EEG continua. Las variables binarias toman valor 1 en el onset del evento y se desplazan diagonalmente con cada lag. La variable continua refleja el valor del predictor en ese retardo.

2.5.3. Estimación Ridge y selección del parámetro de regularización

Los coeficientes del modelo (las TRFs) se estiman mediante regresión Ridge (regularización L2).

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \left[\sum_t \left(r(t) - \sum_{\tau} w(\tau) \cdot x(t - \tau) \right)^2 + \lambda \sum_{\tau} w(\tau)^2 \right] \quad (2.40)$$

El primer término corresponde al error de predicción: qué tan bien el modelo explica la señal EEG observada. El segundo término es la penalización Ridge, que encoge los coeficientes hacia cero y está controlada por el parámetro λ . Esta penalización estabiliza la estimación en presencia de multicolinealidad entre predictores y previene el sobreajuste.

Selección de λ

El parámetro λ se selecciona individualmente para cada participante y modelo mediante la técnica de *cross-validation* de 10 folds. En cada iteración, el modelo se entrena sobre el 90 % de los datos para un conjunto de valores candidatos de λ , y se evalúa sobre el 10 % restante midiendo el coeficiente de correlación de Pearson entre la señal EEG predicha y la señal real. El λ óptimo es aquel que maximiza la correlación promedio entre los 10 folds.

El modelo base: MH1

Cómo punto de partida para el análisis, se adopta el modelo base definido en [que](#), [cita](#) incluye los siguientes predictores:

- **Intercept de fijación:** respuesta media asociada a cualquier fijación sobre un estímulo.
- **Target:** variable binaria que indica si la fijación cayó sobre el target (1) o un distractor (0).
- **Memory Set Size (MSS):** tamaño del conjunto de memoria, codificado ordinalmente como $\{0, 1, 3\}$ para $MSS \in \{1, 2, 4\}$.
- **Correct:** variable binaria que indica si el participante respondió correctamente en ese trial.
- **Intercept de sacada:** respuesta media asociada a cada movimiento sacádico.
- **Splines de amplitud de sacada:** 5 splines cúbicos que modelan la relación no lineal entre la amplitud de la sacada y la respuesta EEG.

La ventana de análisis se define entre -200 ms y $+400$ ms respecto al onset de cada fijación, y entre -200 ms y $+400$ ms respecto al onset de cada sacada.

2.6. Metodología de evaluación

2.6.1. Construcción Incremental de Modelos

Para la evaluación de la contribución de las features extraídas del nnELM se adoptó la estrategia de **construcción incremental de modelos**. Se utiliza como base el modelo MH1 (Sección 2.5) y se incorpora de forma independiente cada feature candidata. Esta estrategia permite aislar el aporte marginal de cada variable antes de considerar combinaciones.

Previo a su incorporación al modelo, cada feature se estandariza mediante z-score intrasujeto: para cada sujeto s y cada feature f , se sustrae la media de los valores de f sobre todas las fijaciones del sujeto a lo largo de todos sus trials, y se divide por el desvío estándar correspondiente.

$$z_{f,s}(t) = \frac{f_s(t) - \mu_{f,s}}{\sigma_{f,s}} \quad (2.41)$$

La estandarización z-score elimina las diferencias de escala, haciendo que los coeficientes TRF resultantes sean comparables entre features con distintas unidades y rangos.

2.6.2. Δ AIC con grados de libertad efectivos de Ridge

El Criterio de Información de Akaike (AIC) es una métrica basada en la teoría de la información que busca el equilibrio óptimo entre la bondad de ajuste de un modelo y su complejidad. El AIC estima la distancia KL (es decir, la información "perdida") entre el modelo propuesto y el mecanismo que generó los datos.

$$\text{AIC} = n [\log(2\pi) + \log(\hat{\sigma}^2) + 1] + 2 df_\lambda \quad (2.42)$$

donde n es el número de observaciones y $\hat{\sigma}^2$ es la varianza del residuo. En el AIC la penalización por complejidad se determina como $2K$, donde K es el número de parámetros del modelo (mayor cantidad de coeficientes, mayor penalización). Sin embargo, el modelo Ridge aplica regularización hacia los coeficientes: los coeficientes no significativos resultan en valores muy cercanos al 0. Esto da como resultado una sobrepenalización en la complejidad del modelo. Como solución, se utilizan los grados de libertad efectivos df_λ . En lugar de contar cuántos coeficientes hay, se mide cuánta libertad real tiene el modelo para ajustarse a los datos después de aplicar la regularización (usando el λ de la regularización).

$$df_\lambda = \sum_i \frac{d_i^2}{d_i^2 + \lambda} \quad (2.43)$$

El Δ AIC se calcula como la diferencia entre el AIC del modelo base y el AIC del modelo extendido, para cada electrodo y cada participante. Dado que no se espera que todos los electrodos respondan a cada feature agregada, se seleccionan para cada sujeto los $N = 32$ electrodos con mayor mejora y se promedian. Este valor se promedia luego entre participantes, obteniendo como resultado un Δ AIC final por feature. Valores más negativos de Δ AIC indican mayor mejora relativa.

2.6.3. VIF

2.6.4. TFCE: Inferencia Estadística Espacio-Temporal

Para realizar un análisis grupal entre los resultados de distintos participantes, se utiliza el método **TFCE (Threshold-Free Cluster Enhancement)**. Este método toma los coeficientes TRF de cada participante, electrodo y muestra temporal, e identifica clusters en el espacio de electrodos $\times$ muestras temporales donde los coeficientes son distintos de cero entre participantes (es decir, la señal es reproducible a nivel grupal). Para evaluar la significancia de cada cluster (llamémoslo cluster original), se realizan 2048 permutaciones

en las que se asigna al azar un signo a los coeficientes de cada participante, y se registra el tamaño del cluster más grande resultante. Si la proporción de permutaciones que produjeron un cluster de tamaño mayor o igual al cluster original es menor al 5 %, se determina que el cluster es significativo, y por lo tanto lo es la variable. En los resultados se reporta qué ventana temporal y en qué electrodos se encontró significancia.

2.6.5. Exploración de Transformación de Variables

A partir del análisis distribucional presentado en la Sección 3.2, varias features exhiben distribuciones fuertemente asimétricas con colas positivas pronunciadas, lo que puede afectar la calidad de la estimación de los coeficientes en un modelo de regresión. Para evaluar si la normalización distribucional mejora la detección de efectos neurales, se aplicaron transformaciones a features que lo requirieran, y se compararon el ΔAIC y los resultados TFCE obtenidos entre la variable original y la transformada. Los criterios para seleccionar qué features transformar y sus resultados se presentan en la Sección 3.2.

3. ANÁLISIS DE FEATURES

3.1. Validación computacional de las features

3.2. Análisis distribucional

Se presenta el análisis distribucional de las features.

El análisis se organiza en torno a dos perspectivas complementarias:

- **Análisis global:** se presentan histogramas y estadísticos descriptivos para cada feature, considerando el conjunto completo de fijaciones del dataset ($N = 61,252$). Esto permite identificar características generales de la distribución, como sesgo, presencia de outliers o valores constantes.
- **Mirada por sujeto:** se examina la variabilidad de cada feature dentro de cada participante por separado. El modelo de regresión se estima de forma independiente para cada sujeto: la matriz de diseño de cada participante contiene únicamente sus propias fijaciones, y los coeficientes TRF resultantes reflejan la relación entre las features y la señal cerebral de ese individuo. En consecuencia, es crucial verificar que las features presentan variabilidad dentro de cada sujeto, ya que una feature constante para un participante no contribuirá a explicar su señal cerebral.

ver como nombra
modelo

3.2.1. Análisis Global

Información Bottom Up

Las features de información bottom-up se encuentran sesgadas a la derecha, con una mayoría de fijaciones que presentan valores bajos. Esto refleja que la mayoría de las fijaciones caen en zonas de baja saliencia.

Tab. 3.1: Estadísticos descriptivos de las features de información bottom-up.

	saliencia_media	saliencia_mediana	saliencia_pixel
count	61252	61252	61252
mean	0.1046	0.1004	0.0449
std	0.1408	0.1391	0.0954
min	0.0000	0.0000	0.0000
25 %	0.0164	0.0157	0.0000
50 %	0.0507	0.0471	0.0078
75 %	0.1309	0.1255	0.0431
max	0.9010	0.9059	1.0000

Similitud con el target

Al igual que las features de información bottom-up, las features de información similitud con el target también se encuentran sesgadas a la derecha, con una mayoría de fijaciones con valores bajos.

Tab. 3.2: Estadísticos descriptivos de las features de similitud con el target.

	similitud_media	similitud_mediana	similitud_pixel
count	61252	61252	61252
mean	0.0910	0.0835	0.0334
std	0.1172	0.1157	0.0715
min	0.0000	0.0000	0.0000
25 %	0.0133	0.0118	0.0039
50 %	0.0452	0.0373	0.0078
75 %	0.1251	0.1098	0.0314
max	0.8268	0.8353	0.9490

Estado interno del proceso bayesiano

fuente: análisis de
features de compe-
a fp

La feature **posterior** es la que presenta mayor sesgo de todo el conjunto. Su distribución se encuentra extremadamente concentrada cerca de cero, con una cola muy larga hacia valores altos. Esto es esperable dado el funcionamiento del modelo bayesiano nnELM: en cada fijación, la probabilidad asignada a la celda fijada es muy pequeña, salvo en las fijaciones finales cuando la posterior se concentra en torno al target. La concentración de **posterior** hacia el final del trial se analiza en la sección 3.3.

Tab. 3.3: Estadísticos descriptivos de las features dinámicas del estado interno (parte I).

	evidencia_visual	competencia_fp_var	competencia_fp_media	competencia_fp_max	posterior
count	61252	61252	61252	61252	61252
mean	-3.36	4.60	-0.195	4.83	0.0152
std	2.28	1.58	0.0835	10.3	0.0939
min	-8.91	0.231	-0.342	≈0	≈0
25 %	-4.69	3.50	-0.243	0.0307	0.00000506
50 %	-3.76	4.50	-0.217	0.484	0.0000230
75 %	-2.71	5.59	-0.183	3.53	0.0000980
max	8.44	13.6	0.298	74.2	1.00

La distribución de **entropia_prior_saliencia** es estrecha ($\text{std} = 0.447$), lo que indica que las imágenes del dataset presentan una complejidad visual similar entre sí. El valor máximo para una distribución uniforme sobre la grilla de $24 \times 32 = 768$ celdas es $\log(768) \approx 6.64$; dado que la media se ubica en 5.45, los mapas de saliencia presentan siempre cierta estructura espacial, sin ser completamente uniformes ni extremadamente concentrados.

Por otro lado, la mediana de **entropia_posterior** se ubica en 6.10, lo que indica una posterior casi uniforme sobre la grilla en la mayoría de las fijaciones. La evolución de esta feature a lo largo del trial se examina en la sección 3.3.

La distribución de **ganancia_informacion** está fuertemente sesgada a la derecha (mediana = 0.052, media = 0.214, máximo = 5.90), lo que indica que la mayoría de las fijaciones aportan poca información sobre la localización del target. Se analiza si las fijaciones con ganancia alta se concentran hacia el final del trial en la sección 3.3.

Tab. 3.4: Estadísticos descriptivos de las features del estado interno (parte II): entropías y ganancia.

	entropia_prior_saliencia	entropia_posterior	ganancia_informacion
count	61252	61252	56751
mean	5.45	5.35	0.214
std	0.447	1.71	0.456
min	3.85	0.0000140	0.00000300
25 %	5.28	5.37	0.0257
50 %	5.48	6.10	0.0517
75 %	5.79	6.38	0.143
max	6.15	6.58	5.90

Calidad de la decisión

La feature `gap_entropia` cuantifica la diferencia entre la ganancia de información esperada en la fijación óptima según el modelo y la ganancia correspondiente a la fijación efectivamente realizada por el sujeto. Su distribución presenta un marcado sesgo a la derecha: la mediana es 0,262 pero la media asciende a 0,711, con un máximo de 4,48, lo que indica que la mayoría de las fijaciones se alejan moderadamente del óptimo pero existen casos de suboptimalidad muy pronunciada. El mínimo exactamente igual a 0 refleja los casos en que el sujeto fija la celda óptima según el criterio ELM. En conjunto, la distribución revela una suboptimalidad sistemática: los sujetos no siguen la estrategia de minimización de entropía que prescribe el modelo.

Las features `distancia_grilla` (mediana = 9,43 celdas) y `distancia_pixels` (mediana = 302 px) complementan este análisis desde una perspectiva espacial. Dado que la grilla tiene 32 columnas, una distancia mediana de 9,43 celdas equivale casi a un tercio del ancho de la imagen, indicando que la mayoría de las fijaciones se encuentran a una distancia considerable del óptimo, coherente con el análisis de `gap_entropia`.

esto es esperable
Buscar y citar

Tab. 3.5: Estadísticos descriptivos de las features de calidad de la decisión.

	gap_entropia	distancia_grilla	distancia_pixels
count	56751	56751	56751
mean	0.711	9.91	317
std	1.04	6.03	193
min	0.000	0.000	0.000
25 %	0.127	5.39	172
50 %	0.262	9.43	302
75 %	0.702	13.9	446
max	4.48	31.8	1016

Competencia entre candidatos

La feature `competencia_ratio` presenta una baja variabilidad relativa (std = 0,056, media = 0,927), lo que indica que casi siempre el segundo mejor candidato alcanza entre

el 89 % y el 97 % del valor del mejor candidato. En otras palabras, el mapa EIG rara vez tiene un único ganador claro: casi siempre hay competencia entre candidatos.

Tab. 3.6: Estadísticos descriptivos de las features de competencia entre candidatos.

	competencia_ratio	competencia_densidad	competencia_densidad_norm
count	61252	61252	61252
mean	0.927	1.79	0.00233
std	0.0562	1.82	0.00237
min	0.763	1.00	0.00130
25 %	0.889	1.00	0.00130
50 %	0.940	1.00	0.00130
75 %	0.974	2.00	0.00260
max	1.00	96.0	0.125

Análisis General

La Figura 3.1 presenta la distribución de las 22 features estandarizadas (z-score) mediante violinplots, agrupadas por categoría. La estandarización permite comparar la forma y dispersión relativa de todas las features en un mismo eje, independientemente de sus unidades y escalas originales. Las líneas internas de cada violín indican la mediana y los cuartiles Q1 y Q3 de la distribución.




Fig. 3.1: Distribución de las features extraídas del modelo nnELM. Cada violín muestra la densidad empírica de la feature correspondiente sobre el conjunto completo de fijaciones ($N = 61,252$).

El análisis de los violinplots permite identificar patrones distribucionales relevantes que complementan los estadísticos descriptivos de las tablas anteriores. Se observan las diferencias en la forma de las distribuciones. Las features **evidencia_visual** y **competencia_fp_media** son las únicas con distribuciones aproximadamente simétricas. El resto presenta asimetría en alguna dirección: las features **posterior**, **ganancia_informacion**, **competencia_fp_max**, **gap_entropia** y **competencia_densidad** muestran una cola pronunciada hacia valores positivos, con masa concentrada en valores bajos y eventos raros de

valores altos. En sentido contrario, `entropia_posterior` y `competencia_ratio` presentan una cola hacia valores negativos, con la masa concentrada en la parte alta de su rango.

3.2.2. Mirada por sujeto

La variabilidad relevante para el modelo de TRFs por regresión regularizada no es la variabilidad global del dataset sino la variabilidad dentro de cada sujeto (variabilidad within-subject). El objetivo de esta sección es analizar cuánto varía cada feature dentro de las fijaciones de un mismo participante. Para cuantificarla se calcularon las siguientes métricas, tomando como unidad de análisis a cada sujeto por separado:

Para cada sujeto s y cada feature f , se calculó el desvío estándar de los valores de f sobre todas sus fijaciones:

$$\sigma_{f,s} = \text{std}(\{f_t : t \in \text{fijaciones de } s\}) \quad (3.1)$$

A partir de este valor se derivaron dos métricas de resumen:

- **Std within-subject mediano** ($\tilde{\sigma}_f$): mediana de $\sigma_{f,s}$ entre los $S = 44$ sujetos. Cuantifica cuánto varía típicamente la feature dentro de un participante, en las unidades originales de la feature.
- **Coefficiente de variación within-subject mediano** ($\widetilde{CV}_f$): mediana del cociente $\frac{\sigma_{f,s}}{\mu_{f,s}}$ donde $\mu_{f,s}$ es la media de la feature para el sujeto s . Al normalizar por la media, esta métrica es adimensional y permite comparar features en distintas escalas. Un valor de $\widetilde{CV}_f = 0,1$ indica que el desvío estándar within-subject es el 10 % de la media.

La Tabla 3.7 presenta las tres métricas calculadas para cada feature, ordenadas de menor a mayor coeficiente de variación within-subject.

Esto está ok acá
bería ir en método

Tab. 3.7: Variabilidad within-subject de cada feature

Feature	$\tilde{\sigma}_f$	$\widetilde{CV}_f$	Categoría
competencia_ratio	0.0558	0.060	Competencia
entropia_prior_saliencia	0.4461	0.082	Est. Bayesiano
entropia_posterior	1.6322	0.304	Est. Bayesiano
competencia_fp_var	1.5731	0.342	Est. Bayesiano
competencia_fp_media	0.0811	0.416	Est. Bayesiano
distancia_pixels	191.399	0.603	Cal. Decisión
distancia_grilla	5.9812	0.603	Cal. Decisión
evidencia_visual	2.2432	0.647	Est. Bayesiano
competencia_densidad	1.4914	0.822	Competencia
competencia_densidad_norm	0.0019	0.822	Competencia
similitud_media	0.1150	1.278	Similitud
saliencia_media	0.1416	1.333	Bottom-Up
similitud_mediana	0.1137	1.369	Similitud
saliencia_mediana	0.1397	1.372	Bottom-Up
gap_entropia	1.0026	1.469	Cal. Decisión
ganancia_informacion	0.4512	2.111	Est. Bayesiano
saliencia_pixel	0.0959	2.123	Bottom-Up
competencia_fp_max	9.9494	2.132	Est. Bayesiano
similitud_pixel	0.0718	2.133	Similitud
posterior	0.0874	6.468	Est. Bayesiano

La feature **competencia_ratio** presenta el coeficiente de variación within-subject más bajo del conjunto ($\widetilde{CV} = 0,060$), consistente con su distribución global estrecha ya observada en el análisis distribucional (std = 0,056, rango [0,763, 1,000]). Dado que esta feature es casi constante tanto a nivel global como dentro de cada sujeto, se la considera candidata a descarte antes del modelado de EEG.

La feature **entropia_prior_saliencia** también presenta un $\widetilde{CV}$ bajo (0,082), pero es esperable al ser estática por trial. Su variabilidad within-subject no refleja la dinámica de búsqueda fijación a fijación sino únicamente las diferencias entre las imágenes vistas por cada participante. Esta característica no implica degeneración, y es consistente con lo observado en el análisis distribucional: la estrechez de su distribución global (std = 0,447, rango [3,85, 6,15] frente al máximo teórico de $\ln(768) \approx 6,64$ nats) refleja que las imágenes del dataset presentan una complejidad visual similar entre sí, lo que naturalmente limita la variabilidad de esta feature tanto entre trials como dentro de cada sujeto.

En el extremo opuesto, las features de saliencia y similitud presentan coeficientes de variación superiores a 1, lo que indica que su desvío estándar within-subject supera a su propia media. Lo mismo ocurre con **ganancia_informacion** ($\widetilde{CV} = 2,111$), **competencia_fp_max** ($\widetilde{CV} = 2,132$) y **similitud_pixel** ($\widetilde{CV} = 2,133$). Estas features presentan la mayor variabilidad relativa dentro de cada sujeto y son por lo tanto las candidatas más robustas como predictores individuales.

Es importante considerar una limitación del coeficiente de variación como métrica de variabilidad: al ser un cociente entre el desvío estándar y la media, su valor se infla artificialmente cuando la media es cercana a cero pero el desvío estándar no lo es pro-

¿se puede usar si tiene sentido con los resultados en el modelo de búsqueda? Ver si agregar resultados o ya no los descartamos x descartamos

porcionalmente. En ese caso, un CV alto no refleja necesariamente una feature con gran variabilidad within-subject sino simplemente una feature cuya media es pequeña en relación a su dispersión.

Esta situación se presenta en `posterior` ($\mu = 0,0135$, $\tilde{\sigma} = 0,087$), `similitud_pixel` ($\mu = 0,0337$, $\tilde{\sigma} = 0,072$) y `saliencia_pixel` ($\mu = 0,0450$, $\tilde{\sigma} = 0,096$): las tres tienen medias pequeñas pero desvíos estándar considerablemente mayores que sus medias, lo que infla el cociente. Esto contrasta con `competencia_densidad_norm`, que también tiene media pequeña ($\mu = 0,00231$) pero cuyos valores están igualmente agrupados cerca de cero ($\tilde{\sigma} = 0,0019$), resultando en un CV moderado (0,822). Por esta razón, el CV de las tres features mencionadas debe interpretarse con cuidado y complementarse con el análisis de su distribución global presentado en la sección anterior.

3.3. Coherencia con el proceso de búsqueda

Para evaluar si las features evolucionan de manera consistente con la dinámica esperada del proceso bayesiano de búsqueda, se analiza su evolución temporal a lo largo del trial. Dado que los trials tienen una cantidad distinta de fijaciones entre sujetos e imágenes, se adoptó la estrategia de mirar hacia atrás desde la última fijación: el índice 0 corresponde a la última fijación del trial, -1 a la penúltima, y así sucesivamente.

Las figuras a continuación muestran, para cada posición $t \in \{-12, \dots, 0\}$, la media de cada feature calculada sobre todos los trials y sujetos que presentan al menos $|t|$ fijaciones previas a la última. Las curvas se estratifican según el resultado del trial: trials en los que el sujeto encontró el target y trials en los que no lo encontró. La banda sombreada representa ± 1 error estándar de la media (SEM), definido como:

$$SEM_t = \frac{\sigma_t}{\sqrt{N_t}} \quad (3.2)$$

donde σ_t es el desvío estándar de los valores de la feature entre los trials en la posición t , y N_t es el número de trials.

Se excluye del análisis a `entropia_prior_saliencia` por ser estática a lo largo de las fijaciones de un mismo trial.

Aclaración sobre el índice temporal

Por una limitación estructural del modelo nnELM, la última fijación humana de cada trial no genera mapa asociado: el loop interno del modelo interrumpe la ejecución antes de procesar esa fijación. En consecuencia, ninguna feature dinámica tiene valor para la última fijación, y el índice $t = 0$ en las curvas corresponde a la *penúltima* fijación humana del trial. En los trials con target encontrado, esto implica que $t = 0$ refleja la fijación inmediatamente anterior a la detección del target, no la fijación sobre el target mismo.

Información bottom-up




Fig. 3.2: Evolución temporal de las features de información bottom-up.

Las features `saliencia_media` y `saliencia_mediana` presentan una tendencia decreciente a lo largo de las últimas fijaciones del trial. Esto indica que a medida que el trial avanza hacia su final, los sujetos tienden a fijar zonas de menor saliencia bottom-up, lo cual es consistente con una búsqueda guiada progresivamente más por información top-down que por atención visual de bajo nivel. En los trials con target no encontrado, los valores son sistemáticamente más bajos que en los trials con target encontrado a lo largo de toda la ventana analizada, con una tendencia decreciente similar.

La feature `saliencia_pixel` no muestra una tendencia temporal clara, con bandas de error amplias que se solapan entre condiciones en la mayor parte de la ventana. Esto es coherente con su naturaleza puntual: el valor en el píxel exacto de fijación es más ruidoso que el promedio sobre la celda completa.

Similitud con el target




Fig. 3.3: Evolución temporal de las features de similitud con el target.

En los trials con target encontrado, `similitud_media` y `similitud_mediana` permanecen relativamente estables hasta $t = -2$, y luego exhiben un incremento pronunciado hacia $t = 0$. Este incremento indica que en la fijación inmediatamente anterior a la detección del target el sujeto ya se encuentra sobre una zona de alta similitud con el objeto buscado.

En contraste, en los trials con target no encontrado ambas features permanecen estables y en niveles más bajos a lo largo de toda la ventana, sin ningún incremento hacia el final.

`similitud_pixel` muestra el mismo patrón cualitativo pero con mayor ruido, consistente con su naturaleza puntual.

Estado interno del proceso bayesiano




Fig. 3.4: Evolución temporal de las features del estado interno del proceso bayesiano.

`evidencia_visual` permanece estable durante la mayor parte de la ventana en ambas condiciones, con un incremento hacia valores menos negativos exclusivamente en $t = 0$ para los trials con target encontrado. Este incremento refleja que en la fijación previa a la detección el sujeto se encuentra sobre una zona con alta similitud con el target, generando una evidencia visual positiva.

Las features de competencia foveal-periférica muestran patrones distintos entre sí. `competencia_fp_media` y `competencia_fp_max` permanecen estables durante la mayor parte del trial y exhiben un incremento abrupto exclusivamente en $t = 0$ para los trials con target encontrado, mientras que en los trials sin target permanecen prácticamente constantes a lo largo de toda la ventana. Para `competencia_fp_var`, no se observa una tendencia clara en los trials sin target.

Para la `posterior` en los trials con target encontrado permanece cercana a cero hasta aproximadamente $t = -3$, momento a partir del cual comienza a crecer aceleradamente. Este crecimiento refleja la concentración progresiva de la distribución posterior en la celda del target a medida que el modelo acumula evidencia en las últimas fijaciones del trial. En los trials sin target, la posterior permanece cercana a cero sin ninguna tendencia creciente.

Este mismo comportamiento se refleja de forma complementaria en `entropia_posterior`: en los trials con target encontrado parte de valores altos y decrece aceleradamente hacia valores cercanos a cero en $t = 0$, mientras que en los trials sin target permanece elevada y estable durante toda la ventana. A medida que la posterior se concentra, la entropía cae; cuando la posterior permanece difusa, la entropía se mantiene alta. Ambas features capturan así la misma dinámica bayesiana desde perspectivas complementarias.

`ganancia_informacion` permanece estable y baja en ambas condiciones durante la mayor parte de la ventana, con un incremento pronunciado en $t = 0$ exclusivamente para los trials con target encontrado. Esto refleja que la fijación previa a la detección genera la mayor actualización bayesiana del trial.

Calidad de la decisión




Fig. 3.5: Evolución temporal de las features de calidad de la decisión.

Las tres features de calidad de la decisión muestran patrones consistentes entre sí. Dado que estas features no están definidas para la última fijación de cada trial, las curvas finalizan en $t = -1$.

gap_entropia PENDIENTE!!!

En **distancia_grilla** y **distancia_pixels** se observa como en los trials con target encontrado, la distancia entre la fijación del sujeto y la predicción del modelo decrece progresivamente hacia el final del trial, indicando que las fijaciones del sujeto se acercan espacialmente a la predicción del modelo. En los trials sin target, la distancia permanece estable durante toda la ventana.

Competencia entre candidatos




Fig. 3.6: Evolución temporal de las features de información bottom-up.

Las tres features de competencia muestran una dinámica similar. En los trials con target encontrado, **competencia_densidad** y **competencia_densidad_norm** presentan valores relativamente estables, seguidos de un descenso pronunciado en $t = 0$. Este descenso indica que en las fijaciones previas a la detección del target el mapa EIG tiende a concentrarse en un único candidato dominante, lo que refleja que el modelo redujo su incertidumbre sobre la localización del target.

En los trials sin target, las tres features permanecen estables y en niveles más bajos que en los trials exitosos durante toda la ventana. **competencia_ratio** muestra bandas de error solapadas entre condiciones durante la mayor parte de la ventana, consistente con su baja variabilidad global ya observada en el análisis distribucional.

3.4. Fijaciones consecutivas en misma celda

Como consecuencia de la diferencia de resolución espacial entre el modelo nnELM, que opera sobre una grilla de celdas, y el registro de eye-tracking, que captura fijaciones a nivel de píxel, puede ocurrir que dos fijaciones consecutivas de un mismo trial sean asignadas a la misma celda de la grilla. En ese caso, surge la pregunta de si ambas fijaciones recibirían valores idénticos para todas las features, lo que introduciría repetición artificial en los predictores del modelo de regresión. Para evaluar la magnitud y el impacto de este fenómeno, se realizó un análisis específico de los pares de fijaciones consecutivas que caen dentro de la misma celda.

Del total de 61,252 fijaciones, 2,908 (4,7 %) comparten celda con la fijación inmediatamente anterior. Este porcentaje varía entre sujetos (rango: 0,6 %–9,6 %), sin que ningún participante presente una proporción que comprometa el análisis.

La Tabla 3.8 presenta, para cada feature, el número de pares con valores idénticos y distintos dentro de los 2,908 pares de fijaciones consecutivas en la misma celda.

Tab. 3.8: Verificación de identidad de valores en pares de fijaciones consecutivas que caen en la misma celda ($N = 2,908$ pares).

Feature	Idénticas	Distintas	% idénticas
<code>saliencia_media</code>	2.908	0	100.0 %
<code>saliencia_mediana</code>	2.908	0	100.0 %
<code>similitud_media</code>	2.908	0	100.0 %
<code>similitud_mediana</code>	2.908	0	100.0 %
<code>entropia_prior_saliencia</code>	2.908	0	100.0 %
<code>competencia_densidad</code>	1.943	965	66.8 %
<code>competencia_densidad_norm</code>	1.943	965	66.8 %
<code>saliencia_pixel</code>	1.596	1.312	54.9 %
<code>similitud_pixel</code>	1.101	1.807	37.9 %
<code>distancia_grilla</code>	197	2.711	6.8 %
<code>distancia_pixels</code>	197	2.711	6.8 %
<code>gap_entropia</code>	24	2.884	0.8 %
<code>evidencia_visual</code>	0	2.908	0.0 %
<code>competencia_fp_var</code>	0	2.908	0.0 %
<code>competencia_fp_media</code>	0	2.908	0.0 %
<code>competencia_fp_max</code>	0	2.908	0.0 %
<code>posterior</code>	0	2.908	0.0 %
<code>entropia_posterior</code>	0	2.908	0.0 %
<code>ganancia_informacion</code>	0	2.908	0.0 %
<code>competencia_ratio</code>	0	2.908	0.0 %

El primer grupo corresponde a las features con valores idénticos en el 100 % de los pares: `saliencia_media`, `saliencia_mediana`, `similitud_media`, `similitud_mediana` y `entropia_prior_saliencia`. Estas features dependen únicamente de la celda y de la imagen, por lo que dos fijaciones en la misma celda reciben necesariamente el mismo valor.

Este comportamiento es esperable y no representa un problema metodológico, sino una consecuencia directa de su naturaleza estática.

El segundo grupo corresponde a las features con valores siempre distintos (0 % de idénticas): `evidencia_visual`, `competencia_fp_var`, `competencia_fp_media`, `competencia_fp_max`, `posterior`, `entropia_posterior`, `ganancia_informacion`, `gap_entropia` y `competencia_ratio`. Para estas features, los mapas internos del modelo nnELM se actualizan en cada fijación independientemente de la celda visitada, por lo que dos fijaciones consecutivas en la misma celda producen valores distintos.

El tercer grupo corresponde a features con comportamiento intermedio, que merecen una explicación particular. `saliencia_pixel` (54,9 %) y `similitud_pixel` (37,9 %) dependen del píxel exacto de fijación dentro de la celda: dos fijaciones en la misma celda pueden caer en píxeles distintos y recibir valores distintos, o en el mismo píxel y recibir valores idénticos. `competencia_densidad` y `competencia_densidad_norm` presentan un 66,8 % de valores idénticos no por ser estáticas sino por su distribución discreta: dado que la mediana es 1 y el Q75 es 2, es frecuente que dos fijaciones consecutivas tengan el mismo valor por coincidencia. Finalmente, `distancia_grilla` y `distancia_pixels` presentan un 6,8 % de valores idénticos, correspondientes a los casos en que el modelo predice la misma celda óptima en dos fijaciones consecutivas.

En conjunto, dado que el fenómeno de fijaciones consecutivas en la misma celda afecta al 4,7 % del total de fijaciones, y que las features dinámicas no presentan valores idénticos en esos pares, se optó por conservar todas las fijaciones sin tratamiento adicional.

3.5. Diagnóstico de Multicolinealidad

¿Entonces vale la pena hacer el análisis de multicolinealidad en cada sujeto?

La presencia de multicolinealidad entre los predictores de un modelo de regresión puede inflar la varianza de los coeficientes estimados y dificultar su interpretación. Si bien la regresión Ridge mitiga este problema mediante la penalización $\lambda \|\beta\|^2$, que estabiliza los coeficientes en presencia de predictores correlacionados, no lo elimina completamente. Por esta razón, se realiza un diagnóstico de multicolinealidad previo al modelado de EEG, con el objetivo de identificar pares redundantes y fundamentar decisiones de descarte antes de incorporar las features al modelo.

Dado que varias features presentan distribuciones fuertemente sesgadas, como se documentó en el análisis distribucional (sección 3.2), se empleó la correlación de Spearman en lugar de la de Pearson. La correlación de Spearman opera sobre los rangos de los datos y es robusta a outliers y a la no normalidad, lo que la hace más apropiada para el conjunto de features analizado.

La Figura 3.7 presenta la matriz de correlaciones de Spearman entre las 20 features candidatas, calculada sobre el pool completo de fijaciones ($N = 61,252$). Los colores rojos indican correlaciones positivas y los azules correlaciones negativas; las etiquetas de cada feature están coloreadas según su grupo de pertenencia.




Fig. 3.7: Matriz de correlaciones de Spearman entre las features candidatas. Los colores de las etiquetas indican el grupo de pertenencia de cada feature. Solo se muestran valores con $|\rho| \geq 0,30$

Se observan bloques de alta correlación intragrupo en Bottom-Up y Similitud: **saliencia_media** y **saliencia_mediana** presentan $\rho = 1,00$, y **similitud_media** y **similitud_mediana** presentan $\rho = 0,99$. Estas correlaciones son esperables dado que ambas features de cada par fueron diseñadas como resúmenes alternativos de la misma información espacial y se incluyeron por separado con el objetivo de evaluar su performance individual en el modelo. Lo mismo ocurre dentro del grupo de Competencia: **competencia_densidad** y **competencia_densidad_norm** presentan $\rho = 1,00$ por ser transformaciones lineales entre sí, y ambas muestran una correlación moderada con **competencia_ratio** ($\rho = 0,85$), también esperable dado que las tres cuantifican distintos aspectos de la misma estructura del mapa FIG.

En segundo lugar, se observan correlaciones altas entre grupos que no fueron anticipadas en el diseño de las features. **entropia_posterior** y **gap_entropia** presentan una correlación negativa de $\rho = -0,79$, y **ganancia_informacion** y **gap_entropia** presentan una correlación positiva de $\rho = 0,69$.

4. RESULTADOS

- 4.1. Resultados con features agregadas
- 4.2. Interpretación de resultados

5. DISCUSIÓN

6. CONCLUSIONES

